

Rozpoznawanie Spamu

Dawid Stasiak s223311
Artur Nejmanowski s223480
Wojciech Seńko s223467
Hubert Murawski s223341
Jakub Rosa s223553

10 czerwca 2025

1. Wprowadzenie

1.1. Streszczenie

Projekt dotyczy klasyfikacji wiadomości e-mail jako spam lub nie-spam (tzw. ham) na podstawie analizy częstotliwości występowania określonych słów w ich treści. Jest to jeden z podstawowych mechanizmów filtrowania spamu w internetowych skrzynkach pocztowych.

1.2. Słowa kluczowe

- **Spam** - W kontekście wiadomości e-mail termin „spam” odnosi się do niechcianych, niezamawianych wiadomości, które są masowo rozsyłane do wielu odbiorców. Zazwyczaj mają one charakter reklamowy, mogą zawierać treści oszukańcze lub stanowić zagrożenie bezpieczeństwa (np. phishing, złośliwe oprogramowanie).
- **Ham** - W kontekście wiadomości e-mail termin „ham” odnosi się do wiadomości legalnych lub pożądaných, czyli przeciwnych do spamu. To zasadniczo e-maile, które użytkownik chce otrzymywać i które nie są uznawane za niechciane lub śmieciowe.

2. Przedmiot analizy

2.1. Cel analizy

Głównym celem badania była ocena, które słowa kluczowe występujące w wiadomościach email są najskuteczniejszymi filtrami spamu. Badanie miało również na celu pokazanie, w jakim stopniu proste cechy językowe mogą być wystarczające do skutecznej filtracji wiadomości w zautomatyzowanych systemach ochrony skrzynek pocztowych.

2.2. Przegląd literatury

Klasyfikacja wiadomości e-mail jako spam lub ham (czyli wiadomości pożądane) jest szeroko badanym zagadnieniem w dziedzinie analizy danych i uczenia maszynowego. W literaturze zaproponowano wiele podejść do tego problemu, z których wiele wykorzystuje analizę częstości występowania słów w treści wiadomości. Różne algorytmy klasyfikacyjne zostały przetestowane i porównane w kontekście skuteczności wykrywania spamu. Na przykład, Wang (6) porównała algorytmy SVM, Naive Bayes i kNN w oparciu o dane tekstowe, wskazując wysoką skuteczność SVM przy odpowiednim doborze cech. Reddy i Ahila (7) wykazali, że las losowy może osiągać lepszą dokładność niż klasyczne metody probabilistyczne. Z kolei Rajput i Arora (8) zaprezentowali skuteczny model oparty na drzewach decyzyjnych, podkreślając znaczenie wyboru odpowiednich parametrów. Dodatkowo, Ouyang, Tian i Wei (9) analizowali skuteczność kNN w klasyfikacji spamu, wskazując na wrażliwość metody na wartość parametru k i strukturę danych. Wyniki tych badań potwierdzają, że wybór metody klasyfikacji oraz sposobu reprezentacji tekstu (np. jako częstości występowania słów) ma istotny wpływ na końcową skuteczność systemu filtrowania spamu.

2.3. Opis cech

Do badania użyto dataset "Spambase" z 1999r., z UCI Machine Learning Repository.

<https://archive.ics.uci.edu/dataset/94/spambase>

W wykorzystanej bazie danych składającej się z 4601 rekordów, wiadomości email opisane są przez 57 cech.

Zmienne oznaczone prefiksem **word_freq** oznaczają częstotliwość występowania danego słowa (48 zmiennych). Podobnie zmienne oznaczone przez **char_freq** oznaczają częstotliwość występowania danego znaku (6 zmiennych). Częstotliwości zdefiniowane są jako stosunek liczby wystąpień znaku/słowa do całkowitej liczby znaków/słów w e-mailu, przemnożony przez 100%.

Dodatkowo obecne są cechy odnoszące się do ilości wielkich liter:

- **capital_run_length_average** – średnia długość nieprzerwanych sekwencji wielkich liter w wiadomości,
- **capital_run_length_longest** – długość najdłuższego nieprzerwanego ciągu wielkich liter w wiadomości,
- **capital_run_length_total** – suma długości wszystkich sekwencji wielkich liter, czyli liczba wszystkich wielkich liter w wiadomości.

Statystyki opisowe cech 1 - 10

	word_freq_make	word_freq_address	word_freq_all	word_freq_3d	word_freq_our	word_freq_over	word_freq_remove	word_freq_internet	word_freq_order	word_freq_mail
count	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0
mean	0.1	0.21	0.28	0.07	0.31	0.1	0.11	0.11	0.09	0.24
std	0.31	1.29	0.5	1.4	0.67	0.27	0.39	0.4	0.28	0.64
min	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
25%	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
50%	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
75%	0.0	0.0	0.42	0.0	0.38	0.0	0.0	0.0	0.0	0.16
max	4.54	14.28	5.1	42.81	10.0	5.88	7.27	11.11	5.26	18.18
skew	5.68	10.09	3.01	26.23	4.75	5.96	6.77	9.72	5.23	8.49

Statystyki opisowe cech 11 - 20

	word_freq_receive	word_freq_will	word_freq_people	word_freq_report	word_freq_addresse	word_freq_free	word_freq_business	word_freq_email	word_freq_you	word_freq_credit
count	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0
mean	0.06	0.54	0.09	0.06	0.05	0.25	0.14	0.18	1.66	0.09
std	0.2	0.86	0.3	0.34	0.26	0.83	0.44	0.53	1.78	0.51
min	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
25%	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
50%	0.0	0.1	0.0	0.0	0.0	0.0	0.0	0.0	1.31	0.0
75%	0.0	0.8	0.0	0.0	0.0	0.1	0.0	0.0	2.64	0.0
max	2.61	9.67	5.55	10.0	4.41	20.0	7.14	9.09	18.75	18.18
skew	5.51	2.87	6.96	11.75	6.97	10.76	5.69	5.41	1.59	14.6

Statystyki opisowe cech 21 - 30

	word_freq_your	word_freq_font	word_freq_000	word_freq_money	word_freq_hp	word_freq_hpl	word_freq_george	word_freq_650	word_freq_lab	word_freq_labs
count	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0
mean	0.81	0.12	0.1	0.09	0.55	0.27	0.77	0.12	0.1	0.1
std	1.2	1.03	0.35	0.44	1.67	0.89	3.37	0.54	0.59	0.46
min	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
25%	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
50%	0.22	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
75%	1.27	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
max	11.11	17.1	5.45	12.5	20.83	16.66	33.33	9.09	14.28	5.88
skew	2.44	9.98	5.71	14.69	5.72	6.35	5.74	6.61	11.37	6.64

Statystyki opisowe cech 31 - 40

	word_freq_telnet	word_freq_857	word_freq_data	word_freq_415	word_freq_85	word_freq_technolog	word_freq_1999	word_freq_parts	word_freq_pm	word_freq_direct
count	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0
mean	0.06	0.05	0.1	0.05	0.11	0.1	0.14	0.01	0.08	0.06
std	0.4	0.33	0.56	0.33	0.53	0.4	0.42	0.22	0.43	0.35
min	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
25%	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
50%	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
75%	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
max	12.5	4.76	18.18	4.76	20.0	7.69	6.89	8.33	11.11	4.76
skew	12.67	10.55	13.19	10.48	15.23	7.67	5.32	28.26	12.06	9.15



Statystyki opisowe cech 41 - 50









	word_freq_cs	word_freq_meeting	word_freq_original	word_freq_project	word_freq_re	word_freq_edu	word_freq_table	word_freq_conferend	char_freq_;	char_freq_()
count	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0
mean	0.04	0.13	0.05	0.08	0.3	0.18	0.01	0.03	0.04	0.14
std	0.36	0.77	0.22	0.62	1.01	0.91	0.08	0.29	0.24	0.27
min	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
25%	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
50%	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.06
75%	0.0	0.0	0.0	0.0	0.11	0.0	0.0	0.0	0.0	0.19
max	7.14	14.28	3.57	20.0	21.42	22.05	2.17	10.0	4.38	9.75
skew	12.59	9.46	7.63	18.77	9.15	10.12	19.87	19.72	13.71	13.58

Statystyki opisowe cech 51 - 57









	char_freq_[]	char_freq_!	char_freq_\$	char_freq_#	capital_run_length_average	capital_run_length_lower	capital_run_length_total
count	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0	4601.0
mean	0.02	0.27	0.08	0.04	5.19	52.17	283.29
std	0.11	0.82	0.25	0.43	31.73	194.89	606.35
min	0.0	0.0	0.0	0.0	1.0	1.0	1.0
25%	0.0	0.0	0.0	0.0	1.59	6.0	35.0
50%	0.0	0.0	0.0	0.0	2.28	15.0	95.0
75%	0.0	0.32	0.05	0.0	3.71	43.0	266.0
max	4.08	32.48	6.0	19.83	1102.5	9989.0	15841.0
skew	21.08	18.66	11.16	31.06	23.76	30.76	8.71


Histogramy dla wybranych dziesięciu cech, w tym dwóch cech odnoszących się do częstotliwości znaków, pięciu cech o częstotliwości słów oraz trzech cech opisujących występowanie wielkich liter w tekście wiadomości e-mail:





Boxploty dla tych samych dziesięciu cech:





2.4. Obróbka danych

2.4.1. Braki w danych

W zbiorze nie występują żadne wartości *Null*, ani nie stwierdzono żadnych błędnych wartości.

2.4.2. Skalowanie danych

Przed uczeniem modeli dane wejściowe zostały poddane standaryzacji za pomocą narzędzia *StandardScaler* z biblioteki *scikit-learn*. Zostało ono wybrane ze względu na wykorzystanie modeli KNN i SVM wrażliwych na skalę cech.



2.5. Obserwacje odstające

2.5.1. Skośność rozkładu

Analiza histogramów zmiennych wykazała bardzo silną skośność w prawo. Większość wartości jest równa zero lub bardzo bliska zero. Poza głównym skupiskiem widać obserwacje przyjmujące znacznie wyższe wartości, będące jednak bardzo rzadkie.

W celu zmniejszenia tego zjawiska na danych przed skalowaniem zastosowano transformację logarytmiczną z dodaną jedynką.

Nie we wszystkich przypadkach eliminowało to skośność, jednak zmniejszyło ją, jak i górną granicę wartości.



Na wykresach widać przykład danych przed i po transformacji

2.6. Podział danych

Dane zostały podzielone na zbiór treningowy i zbiór testowy. Do zbioru treningowego losowo przydzielono 70% danych wejściowych, natomiast do testowego pozostałe 30%.

3. Opis metod

3.1. Drzewo decyzyjne

Drzewo decyzyjne to nieliniowy model predykcyjny, który dzieli zbiór danych na mniejsze, jednorodne podzbiory na podstawie wartości cech. Podział ten jest rekurencyjny i kontynuowany, aż węzły liści osiągną pewien poziom czystości lub nie zostaną spełnione inne kryteria, takie jak osiągnięcie maksymalnej głębokości drzewa, czy minimalnej liczby próbek w liściu. W każdym węźle drzewo wybiera najlepszą cechę i wartość progową do podziału, minimalizując nieczystości w podwęzłach. W projekcie użyliśmy biblioteki scikit-learn, która implementuje zoptymalizowaną wersję algorytmu CART, opisanego w książce pod tytułem “Classification and Regression Trees”(1), którą napisali L. Breiman, J. Friedman, R. A. Olshen i Charles J. Stone

3.2. Las losowy

Las losowy to metoda zespołowa, która polega na tworzeniu dużej liczby drzew decyzyjnych, z których każde trenowane jest na innym losowym podzbiore danych oraz przy użyciu losowo wybranych cech. Każde drzewo działa niezależnie, a końcowy wynik klasyfikacji uzyskuje się poprzez połączenie ich predykcji, najczęściej poprzez wybór klasy, która

została najczęściej wskazana przez wszystkie drzewa. Takie podejście zwiększa odporność modelu na nadmierne dopasowanie do danych uczących i poprawia jego zdolność do generalizacji. Metodę zaproponował, w 2001 roku, Leo Breiman w swojej pracy pod tytułem "Random Forests"(3).

3.3. Support Vector Machines (SVM)

Support Vector Machines (SVM) to metoda uczenia maszynowego, która polega na znalezieniu optymalnej granicy decyzyjnej, maksymalizującej margines między klasami w przestrzeni cech. Dzięki funkcjom jądra, SVM może przekształcić dane do przestrzeni wyższych wymiarów i skutecznie rozdzielać klasy nawet przy nieliniowej separacji. Nadaje się w szczególności do klasyfikacji z dużą liczbą cech. Pierwszy raz została zaproponowana w publikacji "Support-Vector Networks" (2) Corinny Cortes i Vladimira Vapnik

3.4. K-Nearest Neighbors (KNN)

Algorytm K-Nearest Neighbors (KNN) przypisuje nowej próbkę etykietę w oparciu o większość klas jej K najbliższych sąsiadów w przestrzeni cech. Wyróżnia ją to, że nie buduje modelu podczas treningu — jest to metoda leniwa, która przechowuje wszystkie dane treningowe i podejmuje decyzję dopiero w momencie predykcji. KNN działa dobrze w małych i średnich zbiorach, ale może być nieefektywna przy dużych i wysokowymiarowych danych. Metoda została zaproponowana w artykule autorstwa T. Cover'a i P. Hart'a pt. "Nearest neighbor pattern classification"(4).

3.5. Metoda Hybrydowa

Metody hybrydowe w uczeniu maszynowym i data mining to podejścia, które łączą dwie lub więcej różnych technik w celu osiągnięcia lepszej wydajności niż przy użyciu pojedynczych modeli. Stosuje się je szczególnie w złożonych zadaniach, takich jak przetwarzanie języka naturalnego. Nasza metoda hybrydowa łączy ze sobą Drzewo Decyzyjne, Las Losowy, SVM i KNN. Jako jedna z pierwszych zastosowanie metod hybrydowych przedstawiła Ludmila I. Kuncheva w swojej książce pt. "Combining Pattern Classifiers: Methods and Algorithms"(5)

4. Rezultaty

4.1. Wyniki klasyfikacji

4.1.1. Drzewo Decyzyjne

--- Ocena ---


Accuracy: 0.8986

F1 Score: 0.8789

AUC: 0.8976

Classification Report

	precision	recall	f1-score	support
0	0.91	0.91	0.91	804
1	0.88	0.88	0.88	577
accuracy			0.90	1381
macro avg	0.90	0.90	0.90	1381
weighted avg	0.90	0.90	0.90	1381




Po tuningu znaleziono najlepsze parametry dla Drzewa Decyzyjnego:


Najlepsze parametry dla Drzewa Decyzyjnego: {'criterion': 'entropy', 'max_depth': 10, 'min_samples_leaf': 10, 'min_samples_split': 2}
Najlepszy wynik AUC dla Drzewa Decyzyjnego: 0.9549

--- Ocena ---
Accuracy: 0.9117
F1 Score: 0.8899
AUC: 0.9627


Classification Report				
	precision	recall	f1-score	support
0	0.90	0.95	0.93	804
1	0.93	0.85	0.89	577
accuracy			0.91	1381
macro avg	0.91	0.90	0.91	1381
weighted avg	0.91	0.91	0.91	1381




Całość drzewa decyzyjnego:



Fragment drzewa w przybliżeniu:





4.1.2. Las Losowy



--- Ocena ---

Accuracy: 0.9573

F1 Score: 0.9479

AUC: 0.9883


Classification Report					
	precision	recall	f1-score	support	
0	0.95	0.98	0.96	804	
1	0.97	0.93	0.95	577	
accuracy			0.96	1381	
macro avg	0.96	0.95	0.96	1381	
weighted avg	0.96	0.96	0.96	1381	



4.1.3. SVM

--- Ocena ---
Accuracy: 0.9500
F1 Score: 0.9395
AUC: 0.9855


Classification Report		precision	recall	f1-score	support
	0	0.95	0.97	0.96	804
	1	0.95	0.93	0.94	577
accuracy				0.95	1381
macro avg		0.95	0.95	0.95	1381
weighted avg		0.95	0.95	0.95	1381



4.1.4. KNN

--- Ocena ---
 Accuracy: 0.9341
 F1 Score: 0.9202
 AUC: 0.9738

Classification Report					
		precision	recall	f1-score	support
	0	0.94	0.95	0.94	804
	1	0.93	0.91	0.92	577
	accuracy			0.93	1381
	macro avg	0.93	0.93	0.93	1381
	weighted avg	0.93	0.93	0.93	1381




Po tuningu wykonanym dla KNN otrzymano najlepsze parametry:

Najlepsze parametry dla KNN: {'metric': 'manhattan', 'n_neighbors': 13, 'weights': 'distance'}
 Najlepszy wynik AUC dla KNN: 0.9799

--- Ocena ---
Accuracy: 0.9406
F1 Score: 0.9260
AUC: 0.9846

Classification Report				
	precision	recall	f1-score	support
0	0.92	0.98	0.95	804
1	0.97	0.89	0.93	577
accuracy			0.94	1381
macro avg	0.95	0.93	0.94	1381
weighted avg	0.94	0.94	0.94	1381



4.1.5. Metoda hybrydowa (VotingClassifier)

--- Ocena ---


Accuracy: 0.9522

F1 Score: 0.9418

AUC: 0.9891

Classification Report

	precision	recall	f1-score	support
0	0.95	0.97	0.96	804
1	0.96	0.93	0.94	577
accuracy			0.95	1381
macro avg	0.95	0.95	0.95	1381
weighted avg	0.95	0.95	0.95	1381





4.2. Mierniki

4.2.1. AUC

AUC pokazuje jak dobrze model rozróżnia klasy. Im bliższa jedynce jest wartość AUC tym rzadziej model będzie popełniać błędy. Najlepiej sprawdza się, gdy zbiory danych są nie zrównoważone. AUC było dla nas głównym wyznacznikiem przy tuningu modeli. Najbliższą do jedynki wartość AUC osiągnęliśmy przy modelu hybrydowym (0.9891), następnie lesie losowym (0.9883), a

później kolejno SVM (0.9855), KNN (0.9738) i na sam koniec, co jest dość zaskakujące, drzewie decyzyjnym (0.9627).



4.2.2. F1 Score

F1 Score to średnia harmoniczna precyzji (ile pozytywnych wykryć rzeczywiście było pozytywnymi przypadkami w datasetcie) oraz czułości (ile z pozytywnych przypadków zostało wykryte). Wzór na F1 Score wygląda następująco:

$$F1\ Score = 2 \cdot \frac{czułość \cdot precyzja}{czułość + precyzja}$$

Podobnie jak przy AUC, tak też w przypadku F1 Score im bliższa jedynce jest wartość miernika, tym lepiej model funkcjonuje. Dobrze sprawdza się gdy dane są niezerównoważone. W naszym przypadku najlepszy wynik F1 osiągnął model lasu losowego (0.9479), następnie model hybrydowy (0.9418), potem kolejno SVM (0.9395), KNN(0.9202) oraz, znów na samym końcu, Drzewo decyzyjne (0.8899).

4.2.3. Accuracy

Jest to ostatni i najmniej istotny z użytych przez nas mierników. Mierzy on stosunek pomiędzy poprawnymi wykryciami, a liczbą wszystkich przypadków w datasetcie. Jest on o tyle niepewny, że dla niezerównoważonych danych jego wynik może fałszywie wskazywać jakość modelu (drastycznie ją zawyżać). Co prawda dla naszych danych nie jest to duży problem, jednak my skupiliśmy się na pozostałych, bardziej pewnych miernikach. Mimo tego warto wspomnieć, że z naszych modeli najlepsze accuracy osiągnął las losowy (0.9573), następnie model hybrydowy (0.9522), a potem SVM (0.9500), KNN (0.9341) oraz drzewo decyzyjne (0.9117).

4.3. Walidacja

4.3.1. Metoda krzyżowa dla Drzewa Decyzyjnego

```
--- Walidacja Krzyzowa ---  
Scores: [0.95301747 0.95280205 0.958193 0.97489059 0.87878225]  
Mean roc_auc: 0.9435  
Std Dev roc_auc: 0.0334
```

4.3.2. Metoda krzyżowa dla Lasu Losowego

```
--- Walidacja Krzyzowa ---  
Scores: [0.97636186 0.97833237 0.99021223 0.99576972 0.90709222]  
Mean roc_auc: 0.9696  
Std Dev roc_auc: 0.0321
```

4.3.3. Metoda krzyżowa dla SVM

```
--- Walidacja Krzyzowa ---  
Scores: [0.97599899 0.97898522 0.98079044 0.9932969 0.91718648]  
Mean roc_auc: 0.9693  
Std Dev roc_auc: 0.0267
```

4.3.4. Metoda krzyżowa dla KNN

```
--- Walidacja Krzyzowa ---  
Scores: [0.9686059 0.97221934 0.98439347 0.98699974 0.90531248]  
Mean roc_auc: 0.9635  
Std Dev roc_auc: 0.0299
```

4.3.5. Metoda krzyżowa dla metody hybrydowej

```
--- Walidacja Krzyzowa ---  
Scores: [0.97941537 0.98200711 0.9882339 0.99515832 0.92137468]  
Mean roc_auc: 0.9732  
Std Dev roc_auc: 0.0265
```

Najwyższy wynik średniego ROC AUC otrzymano dla metody hybrydowej (0.9732).

5. Przykład użycia modeli

Modele przetestowano na przykładowym e-mailu spam (lewa) oraz e-mailu ham/pożądanym (prawa).

This is to inform you on the release of the EL-GORDO SWEEPSTAKE LOTTERY PROGRAM held on the 29th OF APRIL 2005. Your name is attached to ticket number 025-11-464-992-750 with serial number 2113-05 drew the lucky numbers 13-15-16-21-34-36 which consequently won the lottery in the 3rd category.

You have therefore approved for a lump sum payout of USD 615,810.00 (SIX HUNDRED AND FIFTEEN THOUSAND EIGHT HUNDRED AND SIXTY EIGHT THOUSAND, SEVEN HUNDRED AND TEN UNITED STATES DOLLARS ONLY) in cash credited to file with REF.NO.EG/2251256003/01 and BATCH NO. 000750013. This is from a total cash prize of USD 10,468,770 (TEN MILLION FOUR HUNDRED AND SIXTY EIGHT THOUSAND, SEVEN HUNDRED AND SEVENTY US DOLLARS ONLY) shared among 17 (Seventeen) international winners in this category, CONGRATULATIONS!!!

Your fund is now deposited with a security company and insured in your name. Due to mix up of some numbers and names, we ask that you keep this award from public notice until your claim has been processed and your money remitted to your account as this is part of our security protocol to avoid double claiming or unwarranted taking of an advantage of this program by participants.

All participants were selected through a computer ballot system drawn from 25,000 names from Asia, Australia, New Zealand, Europe, America and North America as part of our international promotions program which we conduct once every year. We hope your lucky name will draw a bigger cash prize in the next years highstake USD 1.3 BILLION inter.lottery.

To begin your claim, please contact your claims agent, DR, ROSA HARRISON the foreign service Manager of SANTA LUCIA SECURITY COMPANY, S.A. on TEL:011 34 653-262-748 FAX: 011-34 675-339-003 for the processing and remittance of your winning prize money to a designation of your choice.

Remember, all prize money must be claimed not later than 4th of July 2005 this date all funds will be returned to the MINISTERIO DE ECONOMIA Y HACIENDA as unclaimed. And also be informed that 10% of your Lottery Winning will be paid to SANTA LUCIA SECURITY COMPANY S.A. after you have received your money.

NOTE: in order to avoid unnecessary delays and complications, please remember to quote your reference and batch numbers in every correspondence with us or your agent. Furthermore, should there be any change of your address do inform your claims agent as soon as possible. Enclosed with this letter is also a payment processing form which you should complete and return to Fax Number 011 34 67-339-003 for immediate processing of your claims.

Congratulations once again from all our members of staff and thank you for being part of our International promotions program.

Yours sincerely,
Jose Luis Miguel
Vice President

Dear Sir or Madam,

We are writing to kindly ask for your support with this year's 19th Film Festival at Greenwood High.

We are concerned that due to a very low number of submissions, the Festival might not take place.

We truly don't want to let that happen.

This year's edition marks the return of the festival tradition at our school after a 5-year break (the last one was canceled due to the pandemic and hasn't been held since).

That's why we are reaching out with a heartfelt request...

As you have participated in previous editions of the Film Festival, we hope you might be willing to submit a film again.

We do not impose any specific theme or genre. We only ask that the film avoids offensive language or scenes, and does not exceed 30 minutes in length.

We sincerely hope for your support.

Warm regards,
Organizers of the 19th Greenwood High Film Festival

Wartości cech dla dwóch e-maili zliczono i przedstawiono w postaci wierszy.

7) Reddy, Y. T. K., & Ahila, S. S. (2022). *Classification of Spam Emails Using Random Forest Algorithm In Comparison With Naive Bayes Algorithm*. Versita. <https://versita.com/menuscrypt/index.php/Versita/article/view/815>

8) Rajput, S., & Arora, A. (2013). *Designing Spam Model – Classification Analysis using Decision Trees*. International Journal of Computer Applications, 75(10). <https://www.ijcaonline.org/archives/volume75/number10/13145-0549>

9) Ouyang, Q., Tian, J., & Wei, J. (2023). *E-mail Spam Classification using KNN and Naive Bayes*. Humanities and Social Science Research, 6(4). <https://drpress.org/ojs/index.php/HSET/article/view/5699>